

学习率调度不是绝热的： 损失曲线预测的一个变化率依赖修正

吴家驹 (2400010711, 本科生)

深度学习 — Task 2 | github.com/wjjpku/DL-final

一句话：现有损失曲线律 (MPL、FSL) 是绝热的——预测的是“准静态”loss (MPL 虽用了 $\Delta\eta_k$, 但对变化率只有 γ 一个旋钮)。我们推导出它们漏掉的、依赖学习率变化率的 **非绝热修正**；其弛豫时间服从经典 $\tau \propto 1/\eta$ (LLM 残差实测 $p = 1.00 \pm 0.18$, AdamW 模拟也复现 $p = 1.01$)，据此实现**参数无关、跨尺度**的损失曲线预测 (陡降误差 -44%)。

本幻灯片为自洽书面报告：每页含设定、结果与加粗结论，无需口头讲解即可读；每个数字都有对应脚本 (末页)。

目录

- ① 问题与复现
- ② 核心: 非绝热修正
- ③ 验证
- ④ 结论

问题: 调度感知的损失曲线预测

目标。 给定学习率 (LR) 调度 $\{\eta_t\}$, 在训练之前预测整条损失曲线 $L(t)$ —— 用来在烧算力之前比较、优化调度。

决定性测试 — 跨调度泛化: 在 **cosine** 上拟合, 预测未见过的 **WSD** 族。

当前最优: Multi-Power Law (MPL), 及其匹配理论 FSL (Li et al. 2025):

$$L(t) = L_0 + A S(t)^{-\alpha} + B \sum_{k \leq t} \Delta \eta_k G(\eta_k^{-\gamma} (S(t) - S(k))), \quad S(t) = \sum_{i \leq t} \eta_i.$$

关键观察 (本工作的出发点)。 这些律确实用了下降量 $\Delta \eta_k$ (MPL 还有 $\eta_k^{-\gamma}$ 这个变化率旋钮), **但对“变化多快”只有 γ 一个经验指数**。它们本质预测的是 **准静态 (绝热) loss** —— 假设损失始终处于当前调度对应的平衡值。 γ 在慢调度上标定后外推不到快衰减。

复现: 忠实重现 MPL / Tissue

设置 (遵循任务)。官方公开损失曲线, 25/100/400M $\times$ 9 调度; **cosine 拟合**、**WSD 测试**; $\log L$ 上的 Huber 损失 + L-BFGS-B 多起点。

规模	Tissue (5p)	MPL (7p)
25M	0.00783	0.00539
100M	0.00486	0.00496
400M	0.00979	0.00852


WSD 平均测试 MAE(cosine 拟合)

我们的 MPL 测试 MAE(0.0054/0.0050/0.0085) 与 Luo et al. 吻合, 复现忠实。

这条拟合良好的 MPL 是后文的基线 —— 我们的修正是加在它之上、并与公平重拟的它对比。

出发点: 绝热律在陡降上留下系统性残差

用拟合良好的 MPL(全过程数据)预测 WSD, 看其在留出曲线上的残差 $r(t) = L_{\text{true}} - L_{\text{MPL}}$:



残差有清晰特征: 稳定段 ≈ 0 ; 在第 20000 步 LR 陡降处突然变正; 越陡越大、WSD 最明显(末段残差 $\text{WSD}/\text{WSDLD} + (6-15) \times 10^{-3}$, cosine ≈ 0)。同样降到 $3e-5$, 陡降的留下滞后、缓降的没有——同终点、变化越快滞后越大, 正是非绝热(变化率依赖)的判据。(红虚线 = $\kappa \text{ DropRelaxS}$, 见后)

想法:MPL 是绝热极限, 残差是非绝热弛豫滞后

机理。 固定 LR 时损失向准静态值 $L_{\text{eq}}(\eta)$ 弛豫 (河谷 landscape 中“山”方向的平衡振荡)。cosine 很慢 $\rightarrow$ 在 cosine 上拟合的 MPL 学到的就是 L_{eq} 。

WSD 衰减太快, 损失来不及弛豫, 滞后在 L_{eq} 之上 $\rightarrow$ 正残差。当 LR 扫描快于弛豫时间 τ 时, 可观测量落后于平衡值 (线性响应 / 非绝热)。

要建模的量

$\Delta L(t) = L(t) - L_{\text{eq}}(\eta_t)$ ——它依赖 LR 的变化率, 而非积分量。下面从 AdamW 动力学把它推出来。

推导 (AdamW): ΔL 是 drop 与 S-时间指数核的卷积

Hessian 特征基下模 i : 曲率 λ_i 、梯度噪声 s_i^2 。 $\beta_2 \rightarrow 1$ 时预条件子停在 $v_i^* \approx s_i^2 \rightarrow$ **Adam 退化为预条件步长 η/s_i 的 SGD**。二阶矩 V_i 的偏差 $\Delta_i = V_i - V_i^*$ 满足精确线性递推, 解得 (慢模 $\eta\lambda_i/s_i \ll 1$, 故 $(1 - \eta\lambda)^2 \approx e^{-2\eta\lambda}$ 很准):


$$\Delta L(t) = \sum_i w_i \left[e^{-2(\lambda_i/s_i)(S-S')} \circledast \text{drop} \right](t), \quad \sum_i w_i = \frac{dL_{\text{eq}}}{d\eta} \text{ (精确恒等式)}.$$

单模塌缩 $\rightarrow$ **可用律**(只多 1 个幅度, 形状常数 λ_{slow}):

$$L = L_{\text{MPL}} + c\eta_{\text{peak}} \frac{dL_{\text{eq}}}{d\eta} \sum_{t'} e^{-\lambda_{\text{slow}}(S_t - S_{t'})} \text{drop}_{t'} \quad (\text{DropRelaxS})$$

推出的可证伪预言: 符号 +; 速率 $\propto \eta \rightarrow \tau \propto 1/\eta$; 幅度 = $dL_{\text{eq}}/d\eta$ (可独立测); λ_{slow} 是**预条件曲率**
 $\rightarrow$ **尺度不变**。

验证 1: 核心预言 $\tau \propto 1/\eta$ 成立 ($p = 1.00 \pm 0.18$)



两段式 wsdcon 在第 8000 步阶跃降到常数 LR, 给出干净的弛豫窗口。拟合残差瞬态

$r(t) \propto e^{-(t-8000)/\tau}$ 得到 τ , 对 LR 的标度:

- 合并 100M+400M: $p = 1.00 \pm 0.18$ (各尺度 $-1.06 / -0.94 / -0.51$);
- 受控 AdamW 模拟也复现 $\tau \propto 1/\eta$ ($p=1.01$); 同模拟里 β_2 消融 τ 持平 (CV 2%) $\Rightarrow \beta_2$ 不给 floor 滞后加通道 (噪声主导, $v \approx s^2$ 不变);
- $p=1$ 正是噪声主导值 $\rightarrow$ 自洽地验证了推导里 $v_i^* \approx s_i^2$ 那步;
- 率常数 $\lambda_{\text{slow}} \approx 10$ 尺度不变, $\eta_{\text{peak}} \lambda_{\text{eff}} \approx 2e-3 \ll 2$ (远低于 edge, 与 γ 相反)。

经典弛豫时间 $\tau \propto 1/\eta$ 在损失曲线残差上被实测确认——理论最硬的证据。

验证 2 & 3: 残差就是推出的项; 幅度可独立预测

验证 2(残差 = 推出的项)。把拟合良好 MPL 的残差对 DropRelaxS_{10} 过原点回归: $R^2 = 0.40/0.80/0.87$ (25/100/400M, 见前图红虚线); 双指数核再涨 0.06–0.07, **证实预言的谱混合**。

验证 3(幅度可预测)。用独立的 noise floor(两段式终值 vs LR) 测 $dL_{\text{eq}}/d\eta$, 预测拟合的 κ : 比值 $\kappa_{\text{fit}}/\kappa_{\text{pred}} = 0.43/0.51/0.60$, **CV 仅 14%** $\rightarrow c \approx 0.5$ 普适 (< 1 来自谱展宽)。

至此

形状常数 λ_{slow} (尺度不变)、校准 $c \approx 0.5$ (普适)、幅度 $dL_{\text{eq}}/d\eta$ (noise floor 可测)——**三者都可独立得到, 修正可“预测”而非“拟合”**。

验证 4: 参数无关的跨尺度预测 (-44%)

λ_{slow}, c 尺度不变 + $dL_{\text{eq}}/d\eta$ 从廉价探针测 $\Rightarrow$ **对目标曲线零拟合**地预测修正: $\lambda_{\text{slow}}=10$ 、 c 取其它尺度留一平均、 $dL_{\text{eq}}/d\eta$ 取目标自身两段式探针。

规模	wsd		wsdld	
	MPL	+ 我们	MPL	+ 我们
25M	0.0034	0.0025	0.0031	0.0022
100M	0.0038	0.0016	0.0033	0.0016
400M	0.0047	0.0024	0.0039	0.0021

留出陡降曲线 MAE; 零拟合

总体 -44% , 胜 6/6(各 $-28\% \sim -56\%$)。

小模型常数 + 一个廉价 noise-floor 探针, 就把大模型陡降曲线预测得比 MPL 迁移好
 $\sim 2\times$ ——正面补 MPL“无跨尺度”的弱点。

诚实的边界 & 与 γ 的关系

什么时候没用 (我不藏)。若你有几条完整 WSD 曲线、直接重拟 MPL, MPL 自己就把残差吸收了 (留出 MAE $0.0037 \rightarrow 0.0032$), 显式项不再加分。对数据充足的 MPL, 这是信息缺口、不是公式缺口。

所以修正的价值在数据稀缺场景: 有 cosine + 廉价探针、但没有完整 WSD 曲线——正是“训练前预测”的真实用途。

与 γ 的关系。MPL 的 $\eta_k^{-\gamma}$ 是对这个非绝热滞后的隐式、低容量近似: 这解释了为什么 γ 必不可少 (3-4 $\times$) 却无法从绝热谱理论推出, 也解释了为什么数据多时 MPL 能靠 γ 吸收残差、few-shot 时不能。

结论

我们做了什么 (覆盖 Task 2 三要素)。

- **问题**: 调度感知损失曲线预测, cosine $\rightarrow$ WSD。
- **复现**: 忠实重现 Tissue & MPL, 对齐已发表精度。
- **方法开发**: 指出现有律皆为绝热, 推导并验证其首个非绝热修正。

核心贡献。

- 绝热/非绝热分解: 损失不仅依赖“花了多少 LR”, 还依赖“花得多快”;
- 从 AdamW 预条件动力学推出 DropRelaxS, 幅度 = $dL_{eq}/d\eta$ (精确恒等式);
- 推出并实测确认 $\tau \propto 1/\eta$ ($p = 1.00 \pm 0.18$), 自洽验证噪声主导;
- 形状常数尺度不变 $\Rightarrow$ **参数无关跨尺度预测, 陡降 -44% 、胜 6/6。**

局限。增益限于数据稀缺的陡降; λ_{slow} , c 是测的非算的; 单一公开数据集、三尺度; 有限 β_2 第二通道待验证。

可复现性

结果	命令
复现 (表 1)	repro/reproduce_cosine_to_wsd.py
残差 = DropRelaxS、 R^2	repro/nonadiabatic_theory.py、deep_stime2.py
$\tau \propto 1/\eta (p=1.00 \pm 0.18)$	repro/deep_tau.py
S-时间核、 λ_{slow} 扫描	repro/deep_stime.py
谱混合 (双指数) 与自治性	repro/deep_rigor.py
参数无关跨尺度预测 -44%	repro/deep_predict.py
公平基线 (信息 vs 公式缺口)	repro/correction_fair.py
推导文档	docs/core/nonadiabatic_correction.md

`pip install -r requirements.txt`; 数据: 官方 MPL 公开曲线, 随仓库置于 `external/MultiPowerLaw/`。

分工与致谢

团队。单人组: 吴家驹 (2400010711, 本科生)——全部工作 (复现、推导、实验、写作) 由唯一作者完成。

资源与参考。数据: 官方 Multi-Power-Law 公开损失曲线 (25/100/400M $\times$ 9 调度)。主要参考:Tissue et al. (2024);Luo et al. (2025, MPL);Li, Chen, Huang, Wang & Wu (2025, FSL);Cohen et al. (2021/22, edge of stability / Adam);Wen et al. (2024, river valley)。

代码与文档:github.com/wjjpku/DL-final

谢谢! 欢迎提问。