

学习率调度不是绝热的

损失曲线预测的一个变化率依赖修正

吴家驹 2400010711

北京大学 深度学习课程 · Task 2

一句话摘要

现有最优的损失曲线律 (Multi-Power Law / Functional Scaling Law) 是**绝热**的：它们预测的是调度在**准静态平衡**下会达到的损失，忽略了当学习率衰减快于系统弛豫时间时，损失会**滞后**于平衡值——留下一个系统性的**正残差**。

我们从 AdamW 的预条件二阶矩动力学**推导出**这个非绝热弛豫滞后项 (DropRelaxS)，其弛豫时间服从经典关系 $\tau \propto 1/\eta$ (LLM 数据实测 $p = 1.00 \pm 0.18$, AdamW 模拟复现 $p = 0.971$)，幅度等于独立可测的平衡地板敏感度 $dL_{eq}/d\eta$ 。在公开同架构尺度上，形状常数经验上较稳定；用少量校准常数做**跨尺度转移**，将留出陡降曲线的预测误差削减 **44%** (6/6 全胜)。

本幻灯片为自洽书面报告：每页含完整的设定、结果与结论，无需口头讲解即可独立阅读。

目录

- ① 封面
- ② 背景与问题
- ③ 核心发现
- ④ 理论推导
- ⑤ 验证
- ⑥ 独立复现
- ⑦ 结论

研究背景：为什么要预测损失曲线？

大语言模型预训练极其昂贵。研究者希望在烧算力之前就能比较不同学习率调度的效果，从而避免昂贵的试错。

核心问题——调度感知的损失曲线预测：

给定学习率调度 $\{\eta_t\}$ ，在训练开始前预测整条损失曲线 $L(t)$ 。

决定性的检验标准：跨调度泛化。

- 仅在 cosine 上拟合模型，测试其能否预测从未见过的 WSD (warmup-stable-decay) 族曲线。
- 这是区分“曲线拟合”与“真正理解调度动力学”的试金石。

当前最优方法。 Multi-Power Law (MPL, Luo et al. 2025) 及其匹配理论 Functional Scaling Law (FSL, Li et al. 2025)。

基线方法：Multi-Power Law (MPL)

MPL 公式 (7 个参数):

$$L(t) = L_0 + A S(t)^{-\alpha} + B \sum_{k \leq t} \underbrace{(\eta_{k-1} - \eta_k)}_{\Delta \eta_k} \left[1 - (1 + C \eta_k^{-\gamma} (S(t) - S(k)))^{-\beta} \right]$$

其中 $S(t) = \sum_{i \leq t} \eta_i$ 为**累积学习率** (intrinsic time / 自然时间)。

各项含义:

- $L_0 + A S^{-\alpha}$: 主干幂律下降 (偏置衰减)。
- $B \cdot LD(t)$: 退火奖励——每次 LR 下降带来的额外 loss reduction 的累积。
- $\eta_k^{-\gamma}$: MPL 唯一的“变化率”旋钮, 凭经验拟合得到 $\gamma \approx 0.64$ 。

关键观察 (本工作的出发点)。MPL 确实使用了 LR 下降量 $\Delta \eta_k$, 且有一个变化率因子 $\eta_k^{-\gamma}$, **但对“变化多快”只有一个经验指数**。它本质预测的是**准静态 (绝热) loss**——假设损失始终 instantaneous 地处于当前 LR 对应的平衡值。

复现基线：忠实重现 MPL 官方结果

数据来源。 MPL 官方公开损失曲线：Llama-2 风格解码器，25/100/400M 三个尺度，各 9 种调度 (cosine, constant, WSD, WSDL, WSDCon-3/9/18, cosine-72k, constant-72k)。

实验设置（遵循课程要求）。

- **训练集**：cosine_24000.csv、cosine_72000.csv（仅 cosine 调度）
- **测试集**：wsd_20000_24000、wsdl_20000_24000、wsdcon_3/9/18（完全外推）
- **目标函数**： $\log L$ 残差上的 Huber 损失；优化器：L-BFGS-B，16 个随机起点取最优。

规模	Tissue (5p)	MPL (7p)
25M	0.00783	0.00539
100M	0.00486	0.00496
400M	0.00979	0.00852

WSD 族平均测试 MAE


我们的 MPL 测试 MAE (0.0054/0.0050/0.0085) 与 Luo et al. 官方 README 值吻合到三位小数，复现忠实。

这条拟合良好的 MPL 是后文全部分析的基线。

发现：绝热律在快速衰减上留下系统性正残差

方法。用上述拟合良好的 MPL（全过程数据训练）预测留出曲线，观察预测残差

$$r(t) = L_{\text{true}}(t) - L_{\text{MPL}}(t)。$$



残差的清晰特征：

- ① 稳定高 LR 段：残差 ≈ 0 （系统处于平衡）。
- ② 第 20000 步 LR **陡降**处：残差突然**跳为正**。
- ③ 衰减越陡，残差越大：WSD/WDLD 末段 $+(6-15) \times 10^{-3}$ ，而 gradual cosine $\lesssim 4 \times 10^{-3}$ 。
- ④ **关键判据**：一个 gradual cosine 和一个 sharp WSD 到达同一最终 LR (3×10^{-5})，**只有陡降的产生滞后**——同终点、变化越快滞后越大，正是非绝热（变化率依赖）效应的教科书特征。

物理解释：绝热极限 vs 非绝热滞后

绝热图像。

- 固定 LR η 时，损失会向一个准静态值 $L_{\text{eq}}(\eta)$ 弛豫。
- cosine 衰减很缓慢 $\rightarrow$ 损失始终紧跟平衡值。
- 在 cosine 上拟合的 MPL，学到的正是 L_{eq} 。

非绝热图像。

- WSD 衰减太快，损失**来不及弛豫**到新的更低平衡值。
- 系统滞留在旧的更高损失状态 $\rightarrow$ 正残差。
- 当 LR 扫描速率 $|\dot{\eta}|$ 超过弛豫速率 $1/\tau$ 时，可观测量系统性落后于平衡值。

绝热律预测

$$L_{\text{pred}} = L_{\text{eq}}(\eta_t)$$

只依赖当前 LR 和累计进度

真实损失

$$L_{\text{true}} = L_{\text{eq}}(\eta_t) + \underbrace{\Delta L_{\text{lag}}}_{>0}$$

额外依赖 LR 变化率

核心问题

ΔL_{lag} 的结构是什么？能否从动力学推导出来？

推导：从 AdamW 预条件动力学出发

模型设置。在 Hessian 特征基下展开，模 i 具有：曲率 λ_i ，梯度噪声标准差 s_i 。

关键简化。当 $\beta_2 \rightarrow 1$ （实际训练中的典型值 0.95–0.999），Adam 的二阶矩预条件子收敛到 $v_i^* \approx \mathbb{E}[g_i^2] = \lambda_i^2 V_i + s_i^2$ 。在噪声主导的“山方向”， $v_i^* \approx s_i^2$ 为常数 $\rightarrow$ **Adam 退化为预条件步长 $\eta_{\text{eff}} = \eta/s_i$ 的 SGD。**

线性递推。二阶矩偏差 $\Delta_i = V_i - V_i^*(\eta_t)$ 满足精确线性递推。对慢模（ $\eta\lambda_i/s_i \ll 1$ ，事后验证成立）， $(1 - \eta\lambda_i/s_i)^2 \approx e^{-2\eta\lambda_i/s_i}$ ，解得：

$$\Delta L(t) = \sum_i \underbrace{w_i}_{dV_i^*/d\eta} \left[\underbrace{e^{-2(\lambda_i/s_i)(S-S')}}_{\text{S-time 指数核}} \circledast \underbrace{\text{drop}}_{(\eta-\eta')_+} \right](t)$$

精确恒等式。权重之和 $= \sum_i w_i = \sum_i \frac{dV_i^*}{d\eta} \cdot \frac{\lambda_i}{2} = \frac{dL_{\text{eq}}}{d\eta}$ 。

可用修正律：DropRelaxS

将谱混合塌缩为最低容量的单极闭合（避免过拟合）：

$$L(t) = L_{\text{MPL}}(t) + c\chi \sum_{k < t} e^{-\lambda_{\text{slow}}(S_t - S_k)} (\eta_k - \eta_{k+1})_+ \quad (\chi = dL_{\text{eq}}/d\eta)$$

各项含义：


- $\chi = dL_{\text{eq}}/d\eta$ ：平衡地板对 LR 的敏感度，**独立可测**（见后）。
- λ_{slow} ：有效预条件曲率，控制弛豫速率；在公开同架构尺度上**经验稳定**（见后）。
- $c \leq 1$ ：将谱混合压缩为单极的校准因子，**近似可迁移**。
- 记忆变量是累积学习率 $S_t - S_k$ ，而非步数 $t - k$ 。

推出的六条可证伪预言：

- ① 符号为正；
- ② 因果依赖 LR decrements；
- ③ 记忆在 S-time；
- ④ 幅度 $= dL_{\text{eq}}/d\eta$ ；
- ⑤ noise-dominated 模： $\tau \propto 1/\eta$ ；
- ⑥ 谱混合：双指数优于单指数。

验证 1: 核心预言 $\tau \propto 1/\eta$ 成立

实验设计。 利用两段式 wsdcon 曲线 (第 8000 步阶跃降到常数 LR), 第二阶段 LR 分别取 $\eta \in \{3, 9, 18\} \times 10^{-5}$ 。拟合残差瞬态 $r(t) \propto e^{-(t-8000)/\tau}$ 提取弛豫时间 τ 。



结果:

- 合并 100M+400M: $p = 1.00 \pm 0.18$
- 各尺度单独: $-1.06 / -0.94 / -0.51$ (100/400/25M)
- 受控 AdamW 模拟复现: $p = 0.971$, $R^2 = 0.9996$
- $\beta_2 \in [0.9, 0.9999]$ 扫描: τ 平坦, CV 仅 1.1%

推论: $p = 1$ 正是**噪声主导**的理论值 $\rightarrow$ 自洽地验证了推导中 $v_i^* \approx s_i^2$ 的关键简化步骤。

经典弛豫时间 $\tau \propto 1/\eta$ 首次在 LLM 预训练的损失曲线残差上被实测确认。

验证 2：残差就是推出的项；谱混合确认

方法。将拟合良好 MPL 的残差对 $\text{DropRelaxS}_{\lambda_{\text{slow}}=10}$ 做**过原点回归**（只有一个斜率参数，防止过拟合）。

结果。

- $R^2 = 0.40/0.80/0.87$ (25/100/400M)，信号随模型规模增长。
- 双指数核替代单指数： R^2 再提升 0.06–0.07，**直接证实谱混合预言**。
- 公平对比：S-time 指数核胜 step-time 核（留出 MAE -21% ），胜无记忆地板 (-3%)。

关键控制。在单条衰减曲线上，有限- λ_{slow} 核与绝热极限 ($\lambda_{\text{slow}} \rightarrow 0$) 数值简并 ($\text{corr} \approx 0.99$)。**速率常数只能由跨调度的对比来约束**——这正是我们使用 wsdcon 系列（不同第二阶段 LR）的原因。

验证 3：幅度可独立预测

方法。不依赖 DropRelaxS 的拟合，**独立地**从两段式终值损失 vs 第二阶段 LR 的关系测 $dL_{eq}/d\eta$ (noise-floor 探针)。

结果。

- 用独立探针预测的理论幅度 $\kappa_{pred} = c \cdot dL_{eq}/d\eta$ 。
- 与 DropRelaxS 回归拟合的幅度 κ_{fit} 比较：

$$\frac{\kappa_{fit}}{\kappa_{pred}} = 0.43 / 0.51 / 0.60 \quad (25/100/400M)$$

- 比值跨尺度 CV 仅 **14%** $\rightarrow c \approx 0.5$ 在公开同架构尺度上近似可迁移。
- < 1 的物理原因：谱混合中快模贡献被单极压缩所忽略。

至此

λ_{slow} (经验稳定) + c (留一校准) + $dL_{eq}/d\eta$ (独立测量) = **低校准跨尺度迁移。**

验证 4：低校准跨尺度迁移（-44%，6/6 全胜）

协议。对目标尺度**不做任何拟合**：

- $\lambda_{\text{slow}} = 10$ （固定常数）
- c 取其他两个尺度的留一法平均
- $dL_{\text{eq}}/d\eta$ 从目标自身的两段式探针测量（与测试曲线不同）

规模	wsd		wsdld	
	MPL	+ 我们	MPL	+ 我们
25M	0.00341	0.00246	0.00314	0.00219
100M	0.00375	0.00164	0.00325	0.00161
400M	0.00470	0.00236	0.00385	0.00212

留出陡降曲线 MAE；目标测试曲线上**零新参数**

总体 -44%，6/6 全胜（各 -28% 至 -56%）。

小模型常数 + 一个廉价 noise-floor 探针，把大模型陡降曲线预测得比 MPL 迁移好 $\sim 2\times$ 。

诚实边界。若已有几条完整 WSD 曲线、直接重拟 MPL，MPL 自己就把残差吸收了（MAE 0.0037 $\rightarrow$ 0.0032），显式项不再加分。**价值在数据稀缺场景**：有 cosine + 廉价探针、但没有完整 WSD 曲线——正是“训练前预测”的真实用途。

独立复现 1: 真实 $\sim 10\text{M}$ transformer

动机。作者原始数据不再公开（仓库 404）。我们在**不同硬件、不同模型、不同数据**上完全独立地重新训练模型，验证机制是否普适。

设置。 $\sim 10\text{M}$ 参数 Llama-2 风格 byte-level 解码器 (RMSNorm + RoPE + SwiGLU)，在 WikiText 上训练。AdamW: $\beta_1 = 0.9$, $\beta_2 = 0.95$, $\text{wd} = 0.1$ 。

三调度设计。到达同一末端 LR ($2.5 \times 10^{-3} \rightarrow 2.5 \times 10^{-4}$)，但扫到那里的速度不同：

调度	末端 loss	累积 LR S
cosine(渐进)	1.0490	8.20
wsd(渐进)	1.0482	9.22
wsd(陡峭)	1.0593	12.59

快扫末端最高，却累积 LR 最多 (+37%)。

任何对 S 单调的损失曲线律（包括 MPL/FSL）都预测：更多累积 LR $\Rightarrow$ 更低损失。

观测到**相反**的排序，无需任何拟合即证实速率相关滞后
的存在。


独立复现 1 (续): 残差结构与 DropRelaxS

在留出曲线 (constant + 两条 wsdcon) 上拟合 MPL (MAE ≈ 0.005), 观察三条测试曲线的残差:

残差按扫描速度排序:

- cosine (最缓): -0.011
- wsd-渐进: -0.004
- wsd-陡峭 (唯一为正): $+0.006$

有限- λ_{slow} 的 DropRelaxS 核在**跨调度联合**上胜过绝热基线: $\Delta R^2 \approx +0.18$ (留出)。



残差仅对陡峭扫描为正, 被 DropRelaxS 捕获

重要说明。在单条衰减曲线上, 有限- λ_{slow} 核与绝热基线数值简并 ($\text{corr} \approx 0.99$)。速率依赖只在**跨调度对比中真实存在**——这与公开 LLM 数据上的观察一致。

独立复现 2: 从零 AdamW 模拟

设置。噪声二次模型 (NQM): 真实 AdamW 迭代 (真实 m , v EMA, 真实 $m/(\sqrt{v} + \epsilon)$ 预条件器, 真实高斯梯度噪声), Monte-Carlo 系综平均作为 ground truth。闭式线性理论仅作独立基线, 绝不既用来生成又用来拟合。

定量复现:

- $\tau \propto 1/\eta$: $p = 0.971$, $R^2 = 0.9996$
- 换种子、留一法均稳健
- $\beta_2 \in [0.9, 0.9999]$: τ 平坦, CV **1.1%**
- 幅度恒等: $dL_{\text{eq}}/d\eta = 3.075$ vs 闭式
 $\frac{1}{4} \sum_i s_i = 3.0$, **误差 < 3%**

谱混合诊断:

- 双峰谱上双指数核提升 R^2 0.065
- 恢复两个注入速率 $\{1, 16\}$ (拟合得 $\{0.87, 16.1\}$)
- **机制在已知谱上被证实为真正的谱混合**

可证伪性: 信号主导谱**破坏** $p = 1$ 。

诚实负结果与开放问题

在 $\sim 10\text{M}$ transformer 上未复现的：

- $\tau \propto 1/\eta$ **在此尺度不成立**： $16\times$ LR 范围上测得 $\tau \approx 475\text{--}912$ 步（几乎平坦， $p \approx 0.18$ ）。审计（合成恢复测试 + profile-likelihood）明确排除窗口截断伪影——这是真实测量，与论文“信号随尺度增长”的声明一致。
- **单曲线核简并**：有限- λ_{slow} 核与绝热基线 $\text{corr} \approx 0.99$ ；速率依赖只在跨调度对比中可辨识。

可复现的不一致性：

- η_{peak} **归一化歧义**：若保留 Eq.(4) 中的 η_{peak} 因子，拟合得 $c \approx 60\text{--}86$ ；只有丢弃它才得 $c \approx 0.5$ 。论文的 $c \approx 0.5$ 绑定于特定（未声明的）归一化约定。

开放问题仍开放：

- 冻结参数的跨形状迁移失败（平均 $R^2 = 0.52$ ，未达预注册门槛 0.6）
- 无 $O(1)$ 拟合常数地从第一性原理计算 λ_{slow} 和 c ——论文开放问题 (a) 未闭合

结论

核心贡献。

- ① 指出现有最优损失曲线律 (MPL/FSL) 皆为**绝热近似**——预测准静态平衡值，忽略快速衰减时的弛豫滞后。
- ② 从 AdamW 预条件二阶矩动力学**推导**出非绝热修正 DropRelaxS，其幅度等于独立可测的平衡地板敏感度 $dL_{eq}/d\eta$ (在受控 NQM 中验证到 3% 内)。
- ③ 推出并**实测确认**经典弛豫律 $\tau \propto 1/\eta$ ($p = 1.00 \pm 0.18$)，自洽验证噪声主导假设。
- ④ 独立复现 (真实 transformer + NQM 模拟) 从两端确认机制，同时**诚实标出边界** (τ 在 $\sim 10M$ 未复现、单曲线简并、 η_{peak} 歧义)。
- ⑤ 形状常数在公开同架构尺度上经验稳定 $\Rightarrow$ **低校准跨尺度迁移**，陡降误差 -44%、6/6 全胜。

局限 (诚实版)。增益限于数据稀缺的陡降； λ_{slow}, c 是测量值而非第一性原理计算； η_{peak} 归一化有歧义； $\tau \propto 1/\eta$ 在 $\sim 10M$ 未复现；跨形状迁移失败；单曲线上核简并；所有真实数据仅来自单一公开数据集的三个尺度。

下一步工作

优先级 1 (补上最大证据缺口):

- **幅度恒等在真实模型上的独立检验**: 在 $\sim 10M$ 模型上训练 3–4 条 constant LR 曲线, 独立测 $dL_{eq}/d\eta$, 与 DropRelaxS 拟合幅度比较。
- **S-time 操控实验**: 改 batch size 使 step-time profile 相同但 S-time 不同, 直接检验记忆变量是 S 而非 t 。

优先级 2 (拓展适用范围):

- 多段递减探针: 不同 drop 幅度、不同第二阶段长度, 验证残差结构。
- NQM 中换 SGD, 检验效应是否不限于 AdamW。
- warmup 对称性: 快速 LR 上升是否产生负残差?

优先级 3 (深入机理):

- 在 NQM 中强制 edge-of-stability 区域, 检验是否能产生 MPL 经验指数 γ 的行为。

可复现性

结果	脚本/文档
MPL 复现 (表 1)	repro/reproduce_cosine_to_wsd.py
残差结构、 R^2 、与 DropRelaxS 回归	repro/nonadiabatic_theory.py
$\tau \propto 1/\eta$ ($p = 1.00 \pm 0.18$)	repro/deep_tau.py
S-time vs step-time 核对比	repro/deep_stime.py、deep_stime2.py
谱混合 (双指数) 与自洽性	repro/deep_rigor.py
低校准跨尺度迁移 -44%	repro/deep_predict.py
公平基线 (信息 vs 公式缺口)	repro/correction_fair.py
独立复现 (represent/)	
NQM 模拟 E1-E6	represent/repro/E*.py
扩展 G1-G5	represent/repro/G*.py
真实 transformer 训练	represent/repro/train.py
曲线分析 + 对抗审计	represent/repro/analyze_*.py
综合报告	represent/REPORT.md

依赖: `pip install -r requirements.txt`。

主数据: 官方 MPL 公开曲线 (`external/MultiPowerLaw/`)。

独立复现数据: 自行训练的模型与 NQM 模拟, 全部种子确定。

谢谢老师审阅！

由于身体原因无法现场汇报，谨以此幻灯片呈报全部工作。

代码与文档：`github.com/wjjpku/DL-final`

论文：`paper/main.tex` (pdfLaTeX 编译)