

从 Cosine 到 WSD: 在 MPL Residual 中识别可迁移的 LR-Drop Response

Source-only calibration without target WSD loss

吴家驹 2400010711

北京大学 深度学习课程 Task 2
github.com/wjjpku/DL-final

中心问题

给定 cosine 训练 loss curve 和目标 WSD-family schedule, 能否在不读取目标 WSD loss 的情况下预测整条 WSD loss curve ?

核心观点

cosine residual 同时混有可迁移的 LR-drop response 和不可迁移的 MPL-LD 参数误差。本文先识别二者, 再只迁移前者。

如何阅读这份报告

这份报告不是从“加一个 κ 修正项”开始，而是从一个 residual identification 问题开始：

MPL residual transfer is hard because residuals are confounded.

环节	问题	证据
Baseline	MPL 是否已经足够强？	官方公开实验复现。
Obstacle	cosine residual 是否能直接迁移？	direct kappa 负控失败。
Identification	如何分离 nuisance drift？	MPL-LD projection。
Prediction	如何构造 target-free correction？	schedule-only ϕ + source-only $\hat{\kappa}$ 。
Validation	识别出的成分是否可迁移？	15/15 WSD-family wins, $\hat{\kappa}$ 对齐 oracle。

读法。先看 residual 为什么混淆，再看 projection 如何提供识别，最后看每个实验验证证据链中的哪一环。

Problem setting: source cosine $\rightarrow$ target WSD

输入。

- source: cosine learning-rate schedule 及其训练 loss curve;
- baseline: MPL 对 source 和 target schedule 的 frozen prediction;
- target: WSD-family learning-rate schedule $\{\eta_t\}_{t=1}^T$ 。

输出。

$$\hat{L}_s(t), \quad t = 1, \dots, T.$$

限制。

calibration uses cosine residual only, target loss is used only for evaluation.

为什么不是普通 curve fitting。 cosine 和 WSD 的 decay geometry 不同。如果 source residual 中的某个成分能迁移到 WSD, 它必须对应 schedule-response mechanism, 而不能只是 source 曲线上的低频拟合误差。

模型尺度。

25M, 100M, 400M.

source curve。

cosine_72000.csv, $r_{\text{cos}}(t) = L_{\text{cos}}(t) - L_{\text{MPL},\text{cos}}(t)$.

本文使用 source suffix $t \geq 8000$ 做 residual calibration; 窗口由 source-side identifiability 检查确定。

WSD-family targets。

文件	含义
wsd_20000_24000.csv	WSD sharp cooldown
wsdld_20000_24000.csv	WSD linear decay
wsdcon_3.csv	WSD-con final LR 3×10^{-5}
wsdcon_9.csv	WSD-con final LR 9×10^{-5}
wsdcon_18.csv	WSD-con final LR 18×10^{-5}

主评估口径。 same-scale WSD-family: 3 个尺度 $\times$ 5 个 target, 共 15 条 target loss curves。

Data processing pipeline

- 1 Read source cosine loss and LR schedule.
- 2 Read frozen MPL prediction.
- 3 Compute source residual:

$$r_{\cos}(t) = L_{\cos}(t) - L_{\text{MPL},\cos}(t).$$

- 4 Use calibration suffix $t \geq 8000$.
- 5 For each target WSD schedule, compute LR drops d_t and response feature ϕ .
- 6 Construct MPL-LD tangent basis and projection P_{LD} .
- 7 Estimate source-only $\hat{\kappa}$.
- 8 Predict target loss; target loss is used only after prediction for evaluation.

Fixed protocol

- source suffix: $t \geq 8000$
- logging interval: $\Delta_{\text{obs}} = 128$
- response time: q_2 half-life rule
- ridge floor: $1/N_{\text{cal}}$
- constraint: $\kappa \geq 0$
- metrics: MAE, RMSE, terminal error

Data source. All main loss curves are stored under `external/MultiPowerLaw/...`, with subfolders `csv_25`, `csv_100`, and `csv_400`.

Strong baseline: MPL 是 frozen 且可复现的

本文以 MPL prediction 作为 frozen baseline:

$$L_{\text{MPL},s}(t) = L_{0,s} + A_s S_s(t)^{-\alpha_s} + B_s D_s(t; C_s, \beta_s, \gamma_s).$$

本文研究的是 MPL residual:

$$r_s(t) = L_s(t) - L_{\text{MPL},s}(t).$$


Scale	R2	MAE	RMSE	PredE	WorstE
25M	0.998802	0.003760	0.004652	0.001102	0.004095
100M	0.998301	0.004348	0.005919	0.001425	0.005829
400M	0.997762	0.004835	0.007305	0.001679	0.009948

定位。复现指标与 MPL README 基本一致。因此本文不是构造一个弱 baseline 再修正，而是在强 MPL baseline 上研究 residual transfer。

Reproduction details

复现对象是 MPL 官方公开实验 / frozen MPL prediction。本文不重新训练 MPL，也不在 WSD target loss 上重拟合 MPL。主要困难包括 logging grid 对齐、不同 scale 的文件对应关系、以及 MPL-LD 参数项的有限差分 tangent basis 构造。关键差异是：复现 MPL 后，只在其 residual 上做 source-only correction。

Diagnostic observation: MPL errors concentrate near transition / tail



读图。红线是 MPL prediction error, 灰线是 normalized LR。本页读取 target true loss, 只用于说明 MPL error 的形状; 它不参与 $\hat{\kappa}$ calibration。在 WSD sharp / linear 中, MPL error 在 LR decay 后的 tail 区域出现系统偏移; 在 WSD-con 中, final LR 改变会带来不同的 residual shape。

问题。这些结构看起来和 LR schedule 有关, 但 source cosine residual 里是否也含有同一种可迁移成分?

Key obstacle: cosine residual 是混合信号

如果直接从 cosine residual 拟合一个 response amplitude:

$$\hat{\kappa}_{\text{direct}} = \frac{\langle \phi_{\lambda, \cos}, r_{\cos} \rangle +}{\|\phi_{\lambda, \cos}\|_2^2 + 1/N_{\text{cal}}},$$

隐含假设是:

$$r_{\cos}(t) \approx \kappa \phi_{\lambda, \cos}(t).$$

这个假设太强。

更合理的局部分解是:

$$r_{\cos}(t) = \underbrace{\kappa \phi_{\lambda, \cos}(t)}_{\text{transferable LR-drop response}} + \underbrace{J_{\text{LD}}(t) \Delta \theta_{\text{LD}}}_{\text{non-transferable MPL-LD nuisance}} + \epsilon(t)$$

直觉。 cosine decay 很平滑, $\phi_{\lambda, \cos}$ 是低频曲线; MPL-LD 参数误差同样会形成低频 drift。如果不先识别二者, κ 会吸收不可迁移的 MPL 参数误差。

Negative control: 直接迁移 cosine κ 会失败

estimator	Pearson vs κ^*	kappa RMSE	mean MAE change	wins
direct no-projection kappa	-0.849	0.6294	+625.92%	0/15
projected kappa	+0.910	0.0103	-30.88%	15/15

结论。问题的核心不是“能不能给 MPL 加一项 residual correction”，而是**能不能在 source residual 中识别出可迁移的那一部分**。

本文重新表述的任务

在 MPL residual 中分离：

transferable LR-drop response vs. MPL-LD nuisance drift.

只迁移前者，不迁移后者。

Core idea: project out MPL-LD tangent nuisance

MPL 的 learning-rate dependent term 依赖:

$$\theta_{\text{LD}} = (B, C, \beta, \gamma).$$

若这些参数存在小偏差, 则 MPL prediction 的一阶误差为:

$$\Delta L_{\text{MPL}}(t) \approx J_{\text{LD}}(t) \Delta \theta_{\text{LD}},$$

其中:

$$J_{\text{LD}}(t) = \left[\frac{\partial L_{\text{MPL}}}{\partial \log B}, \frac{\partial L_{\text{MPL}}}{\partial \log C}, \frac{\partial L_{\text{MPL}}}{\partial \log \beta}, \frac{\partial L_{\text{MPL}}}{\partial \log \gamma} \right].$$


令 P_{LD} 是 J_{LD} 张成空间的正交投影。在估计 response amplitude 前, 先做:

$$x = (I - P_{\text{LD}}) \phi_{\lambda, \cos}, \quad y = (I - P_{\text{LD}}) r_{\cos}.$$

含义。 只在 MPL-LD 局部参数扰动解释不了的 residual 方向上估计可迁移 response。

What projection removes from cosine residual

100M source cosine, calibration suffix $t \geq 8000$; lambda from WSD sharp



读图。 左图显示 raw cosine residual 和 raw response feature 都是低频形状；中图显示 MPL-LD tangent space 能解释 residual 中的大部分 smooth drift；右图显示去掉 nuisance 后，估计 κ 的对象变成 projected residual 与 projected feature 的 alignment。

结论。 projection 不是抽象的线性代数装饰，而是在 source cosine residual 中去掉不可迁移的 MPL-LD drift。

Prediction rule: 最小可部署模型

投影识别之后, WSD prediction 使用:

$$\widehat{L}_s(t) = L_{\text{MPL},s}(t) + \widehat{\kappa}_s \phi_{\lambda_s,s}(t)$$

部分	含义
$L_{\text{MPL},s}(t)$	frozen MPL baseline。
$\phi_{\lambda_s,s}(t)$	target schedule 诱导的 causal LR-drop response shape。
λ_s	response decay rate, 由 target schedule 的 q_2 half-life rule 给出。
$\widehat{\kappa}_s$	唯一从 loss residual 中估计的 scalar; 只用 source cosine residual。

一句话。 target schedule 决定 response shape, source residual 决定 response amplitude。预测 WSD 时不读取 WSD loss。

Causal LR-drop response: schedule-only shape

定义 positive LR drop:

$$d_t = [\eta_{t-1} - \eta_t]_+.$$

当 LR 不下降时, $d_t = 0$ 。

定义响应递推:

$$z_t = \exp(-\lambda_s \eta_t) z_{t-1} + d_t, \quad \phi_{\lambda_s, s}(t) = \frac{z_t}{\eta_{\max}}.$$

展开为:

$$\phi_{\lambda_s, s}(t) = \frac{1}{\eta_{\max}} \sum_{u \leq t} d_u \exp \left(-\lambda_s \sum_{v=u+1}^t \eta_v \right).$$

解释。 LR drop 是 forcing; 每次 drop 注入一个 residual impulse; 这个 impulse 随 cumulative LR time 衰减。因此 ϕ 是 schedule-only、causal、target-loss-free 的 shape。

response time scale。 λ_s 由 schedule-only half-life rule 固定: diffuse LR decay 得到更长 response time, sharp LR drop 得到更短 response time。该规则不读取 target loss; 具体 q_2 定义放在 appendix。

在 source cosine suffix 上定义:

$$x_s = (I - P_{LD})\phi_{\lambda_s, \text{cos}}, \quad y = (I - P_{LD})r_{\text{cos}}.$$

估计问题是:

$$\min_{\kappa \geq 0} \|y - \kappa x_s\|_2^2 + \frac{1}{N_{\text{cal}}} \kappa^2.$$

闭式解:

$$\hat{\kappa}_s = \frac{[x_s^\top y]_+}{\|x_s\|_2^2 + 1/N_{\text{cal}}}$$

解释。 $\hat{\kappa}_s$ 是 projected response feature 的 amplitude。它不是多参数 residual regressor; 如果 projection 后 x_s 与 y 没有正向 alignment, 则该 response 不被激活。


Target-leakage audit: 哪些量读了 target loss

source cosine residual $\rightarrow$ projected $\hat{\kappa}$; target LR schedule $\rightarrow \phi$; frozen MPL + $\hat{\kappa}\phi \rightarrow$ prediction; target loss $\rightarrow$ evaluation only.

stage	used quantities	WSD loss?	role
Calibration	cosine_72000.csv , cosine LR, MPL cosine prediction	no	compute source residual and $\hat{\kappa}$
Target feature	target LR schedule	no	compute $q_2, \lambda_s, \phi_s(t)$
Prediction	target MPL prediction, $\phi_s(t)$, source-only $\hat{\kappa}$	no	output $L_{\text{MPL}} + \hat{\kappa}\phi$
Evaluation	target loss curve	yes	compute MAE and terminal error
Oracle diagnostics	target residual / target MAE grid	yes	only for κ^* , oracle λ

结论。 deployable prediction 阶段不读取 target WSD loss。所有读取 target loss 的量都标记为 evaluation 或 oracle diagnostic，不参与模型部署。

Claim 1: target-free correction improves WSD prediction




Mean MAE change	Worst row	Wins	Target-loss calibration
-30.88%	-4.67%	15/15	0

读图。每个格子是一条 target loss curve 相对 MPL 的 MAE change。蓝色表示误差降低。

含义。在不读取 target WSD loss 的设置下，识别出的 LR-drop response 在全部 15 条 WSD-family 曲线上降低 MAE。

Representative curves: 作用在 transition / tail





读图。上排比较 true loss、MPL 和 $L_{\text{MPL}} + \hat{\kappa}\phi$ ；下排画 prediction error。修正主要发生在 LR transition / tail 区域，而不是对整条曲线做任意平移。

Claim 2: source $\hat{\kappa}$ aligns with target oracle κ^*





oracle diagnostic。

$$\kappa_s^* = \frac{[\langle \phi_{\lambda_{s,s}}, L_s - L_{\text{MPL},s} \rangle]_+}{\|\phi_{\lambda_{s,s}}\|_2^2}.$$

κ^* 读取 target loss, 不能用于 prediction;
它只用于检查 source-only $\hat{\kappa}$ 是否接近 target-own optimum。
读数。 projection 后 Pearson +0.910;
no-projection 负控为 -0.849。



Projection ablation: with projection / without projection



读图。上排用同一尺度比较 MPL error 与 projected $\hat{\kappa}$ ；下排显示 no-projection κ 会把 source residual 中的低频 drift 当成 response amplitude，导致 target error 大幅偏移。

结论。projection 的作用不是提升表格分数，而是阻止不可迁移的 MPL-LD nuisance 被迁移到 WSD。

Cross-scale transfer: amplitude 有信号, 但 raw residual 不能粗暴合并

protocol	Pearson	mean MAE change	worst	wins
same scale	+0.910	-30.88%	-4.67%	15/15
leave-one-scale-out mean κ	+0.671	-25.62%	-3.96%	15/15
all-scale mean κ	+0.808	-29.15%	-4.20%	15/15
single external source scale	+0.731 ~ +0.921	-21.90% ~ -27.06%	-3.15%	10/10 each
pooled raw residuals	+0.641	+62.57%	+231.45%	1/15

解释。跨尺度时, 先各自估计 κ 再聚合, 比直接拼 residual 更合理。这说明 response amplitude 有跨尺度信号, 但 residual 的绝对尺度不能粗暴合并。

本文的 residual model 保持低容量:

$$\widehat{L}_s(t) = L_{\text{MPL},s}(t) + \widehat{\kappa}_s \phi_{\lambda_s,s}(t).$$

模块	来源	residual-fitted 参 数数
$\phi_{\lambda_s,s}$	target LR schedule	0
λ_s	schedule-only half-life rule	0
P_{LD}	MPL tangent basis	0
$\widehat{\kappa}_s$	source cosine residual projection	1

风险控制。没有按 target family 选择 channel, 没有任意 basis expansion, 也没有 target-loss-tuned residual regressor。主要过拟合风险来自 calibration window 与 schedule-family 覆盖范围。

问题	观察
What works	WSD-con 上 9/9 curves 都降低 MAE, 说明主要 step/tail response 被捕获。
What remains weak	WSD-con 内部 final-LR 细粒度排序仍弱: $\hat{\kappa}$ 对 $3e-5, 9e-5, 18e-5$ 的幅度区分不足。
Next evidence needed	更多 WSD-con final LR runs, 或一个明确受 scale / final LR 约束的 amplitude model。

解释。当前 ϕ 的 shape 能抓住主要 transition/tail response; 但 final-LR dependent amplitude variation 还没有被完全识别。完整数值表放在 appendix。

可以说

- 在 frozen MPL baseline 上, source cosine residual 中存在可迁移的 LR-drop response amplitude;
- MPL-LD tangent projection 是识别该成分的关键步骤;
- same-scale WSD-family 15 条曲线全部优于 MPL;
- $\hat{\kappa}$ 与 target oracle κ^* 的 Pearson 为 +0.910;
- leave-one-scale-out mean- κ cross-scale 仍为 15/15 wins。

不能说

- 不能声称得到通用训练 loss 定律;
- 不能声称 $t \geq 8000$ 是普适常数;
- 不能声称 WSD-con final-LR 细粒度排序已经解决;
- 不能声称已经覆盖所有 LR schedule family。

当前证据上限

当前仓库中 same-scale WSD-family 只有五类 target: sharp、linear、WSD-con $3e-5$ 、 $9e-5$ 、 $18e-5$ 。现有 ablation 能说明 projection、 λ 、kernel、cross-scale 的合理性，但不能替代真正新增 schedule 的 held-out 验证。

最关键的下一步

The remaining validation gap is not another ablation on existing curves, but new held-out WSD-family training runs after freezing the protocol.

冻结规则。

$$t \geq 8000, \quad q_2 \text{ half-life}, \quad P_{LD}, \quad 1/N_{\text{cal}} \text{ ridge floor}, \quad \kappa \geq 0.$$

新增 schedule 维度。cooldown 起点、decay length、final LR、sharp 与 linear 之间的中间形态。

- ① **Problem formulation.** 在 frozen MPL baseline 之上, 把 cosine-to-WSD residual transfer 明确表述为 identification problem:
transferable LR-drop response vs. MPL-LD nuisance drift.
- ② **Identification method.** 使用 MPL-LD tangent projection 去除 source residual 中的局部参数误差方向, 再用一维非负 ridge projection 得到 deployable $\hat{\kappa}$ 。
- ③ **Evidence.** projected source $\hat{\kappa}$ 与 target oracle κ^* 对齐, 并在 15/15 same-scale WSD-family curves 上降低 MAE; no-projection 负控则系统失败。

核心贡献不是 feature stacking, 而是 residual identification。

课程要求	对应位置
1. 问题背景与目标：说明研究内容、动机和核心问题。	slides 1–3
2. 数据处理与实验设置：数据来源、处理流程、模型/方法和必要参数。	slides 4–6, 12–14
3. 复现实验结果：报告已有方法复现情况，并说明关键差异或困难。	slide 6
4. 方法与结果对比：说明本文方法，展示实验结果及 baseline 对比。	slides 8–20
5. 分析与思考：结果分析、failure mode、scope 和后续验证缺口。	slides 21–24
6. 代码与分工：仓库、脚本入口、环境、输出和完成方式。	last slide

说明。主文围绕 residual identification 展开；appendix 保留 q_2 细节、kernel 消融、calibration window、MPL L_G audit 与完整 failure-mode 数值表。

从 cosine 到 WSD 的关键，不是更强地拟合 residual，
而是识别 residual 中哪一部分是可迁移的 LR-drop response。

$$\hat{L}_s(t) = L_{\text{MPL},s}(t) + \hat{\kappa}_s \phi_{\lambda_s,s}(t)$$

主要结果

$\hat{\kappa}$ vs. κ^* : Pearson = +0.910.

same-scale WSD-family: - 30.88% mean MAE change, 15/15 wins.

Appendix A: q_2 half-life rule 细节

loss 只在离散 logging points 上观测。设主要 logging interval 为:

$$\Delta_{\text{obs}} = 128, \quad \lambda_{\text{obs}} = \frac{\log 2}{\eta_{\text{max}} \Delta_{\text{obs}}}.$$

令总 drop 和归一化 drop mass 为:

$$D_s = \sum_t d_t, \quad p_t = \frac{d_t}{D_s}.$$

定义 Herfindahl concentration:

$$q_s = \sum_t p_t^2 = \frac{1}{n_{\text{eff}}}.$$

本文使用:

$$\lambda_s = \frac{\lambda_{\text{obs}}}{2 - q_s}$$

直觉。diffuse decay 对应约 $2\Delta_{\text{obs}}$ half-life; single sharp drop 对应约 Δ_{obs} half-life。该规则只读 schedule, 不读 target loss。

Appendix B: Why one-pole exponential response?

本文把 LR drop 看成 forcing, 把 residual relaxation 看成一阶线性系统的 low-capacity closure:

$$z_t = \exp(-\lambda_s \eta_t) z_{t-1} + d_t.$$

三点解释:

- ① LR drop 不是持续输入, 而是离散 forcing: $d_t = [\eta_{t-1} - \eta_t]_+$ 。
- ② 如果系统对 forcing 的恢复可由一阶状态变量近似, 则状态按 cumulative LR time 衰减。
- ③ 一阶线性系统的 Green's function 就是 exponential kernel:

$$\exp \left(-\lambda_s \sum_{v=u+1}^t \eta_v \right).$$

边界。这不是严格训练动力学定理, 而是一个 one-pole closure assumption。kernel ablation 用来检查它是否比同容量替代更合理。

Appendix C: λ / kernel robustness

λ sensitivity	rule	mean MAE	wins
	q_2 half-life	-30.88%	15/15
	fixed $1\Delta_{\text{obs}}$	-17.52%	15/15
	fixed $2\Delta_{\text{obs}}$	+20.63%	7/15
	wrong fast $\lambda = 20$	-14.76%	15/15
	oracle grid best	-31.55%	15/15

same-capacity kernel	one-scalar feature	mean MAE	wins
	LR-time exp drop	-30.88%	15/15
	signed LR-time	-30.24%	15/15
	step-time exp	-3.05%	15/15
	cumulative drop	+27.15%	7/15
	power-law LR-time	+119.07%	1/15

读数。oracle grid best 读取 target loss, 只是上界诊断; q_2 half-life 不读取 target loss, 但接近 oracle。同容量替代说明, 不是任意 schedule-derived scalar 都能解释 residual transfer。

候选 suffix 只用 source cosine 检查 projected response 是否可辨识:

$$\rho = \frac{\|(I - P_{LD})\phi\|_2^2}{\|\phi\|_2^2}, \quad \rho \leq 1/N_{\text{cal}}.$$

fit start	max retention	floor $1/N_{\text{cal}}$	pass	target result
5000	0.013748	0.001912	no	+139.64%, 0/15
6500	0.004225	0.001953	no	+21.07%, 4/15
8000	0.001478	0.002000	yes	-30.88%, 15/15
10000	0.000489	0.002066	yes	-9.85%, 15/15
12000	0.000353	0.002132	yes	-1.82%, 6/15

读数。规则选择最早通过的 $t \geq 8000$ 。target loss 不参与窗口选择；窗口 sweep 只作为事后敏感性分析。

Appendix E: 为什么不是简单调整 MPL 最后一项

MPL 的最后一项 $L_G(t) = B_s D_s(t)$ 本身也与 LR schedule 有关。自然怀疑是：

$$\text{proposed correction} \approx \rho L_G(t).$$

scalar multiplier audit:

setting	proposed correction	oracle scalar ρL_G	scalar R^2
all core	about -30%	-8.91%	$+0.039$
WSD final	about -45%	-17.80%	$+0.036$
WSD-con	-21.14%	-2.98%	$+0.040$

结论。调整 MPL 最后一项系数是有意义的 ablation，但它不能解释本文 residual correction 的主要形状： ϕ 是 LR-drop causal response，不是 $L_G(t)$ 的常数倍。

Appendix F: WSD-con failure-mode 数值表

scale	target	$\hat{\kappa}$	κ^*	ratio	MAE change
25M	3e-5	0.0186	0.0243	0.766	-44.65%
25M	9e-5	0.0186	0.0206	0.904	-21.19%
25M	18e-5	0.0186	0.0338	0.551	-9.19%
100M	3e-5	0.0327	0.0317	1.032	-42.76%
100M	9e-5	0.0327	0.0227	1.444	-9.84%
100M	18e-5	0.0327	0.0217	1.506	-12.80%
400M	3e-5	0.0318	0.0504	0.631	-35.97%
400M	9e-5	0.0318	0.0376	0.845	-9.17%
400M	18e-5	0.0318	0.0277	1.149	-4.67%

读数。每条 WSD-con curve 的 aggregate MAE 都改善；但 $\hat{\kappa}$ 与 κ^* 的 ratio 在 final LR 内部并不稳定。

仓库中同一套 scale 下可用的 WSD-family target 是:

{sharp, linear, WSD-con 3e-5, WSD-con 9e-5, WSD-con 18e-5}.

因此当前的 held-out / robustness 分析只能在这些曲线内部做 protocol audit。

下一步最关键实验。冻结以下规则后, 新增 2–4 条 WSD-family training runs:

$$t \geq 8000, \quad q_2 \text{ half-life}, \quad P_{\text{LD}}, \quad 1/N_{\text{cal}} \text{ ridge floor}, \quad \kappa \geq 0.$$

新增 schedule 可以改变:

- cooldown 起点;
- decay length;
- final LR;
- sharp 与 linear 之间的中间形态。

目的。验证该 identification protocol 不是在现有 5 类 WSD target 上调出来的。

产物	内容
robustness_audit.py	λ sensitivity、kernel ablation、cross-scale、window、failure mode、figures。
REPORT.md	新增 robustness audit 的完整表格和文字解释。
LEAKAGE_AUDIT.md	target-leakage checklist。
slides/figs/	heatmap、representative error curves、MPL residual anomaly、projection decomposition、projection ablation、kappa scatter。

复现命令。

```
python3 repro/schedule_response_robustness_audit.py  
cd slides && xelatex main_zh.tex && xelatex main_zh.tex
```

GitHub:

github.com/wjjpku/DL-final

Main scripts

- reproduce MPL baseline:
`python3 repro/reproduce_cosine_to_wsd.py`
- run MPL-LD projected kappa:
`python3
repro/schedule_response_robustness_audit.py`
- generate figures / tables:
`python3
repro/schedule_response_robustness_audit.py`

Required environment

- Python 3
- numpy, pandas, scipy, matplotlib
- scikit-learn, tqdm, requests
- XeLaTeX for Chinese slides

Outputs

- MPL reproduction metrics
- WSD-family MAE / RMSE tables
- kappa-oracle scatter plots
- projection ablation figures
- slides and audit reports

Division

个人完成

本项目为个人完成：方法设计、代码实现、实验运行、图表生成、报告撰写均由吴家驹完成。MPL baseline 复现基于公开实现 / 公开数据，相关引用与改动见仓库说明。